

# Informe Final

Grupo 14

## Índice

1. Introducción	2
2. Descripción de los datos	2
3. Exploración de datos	3
4. Temática central del proyecto	5
5. Descripción del proceso	6
6. Evaluación de Resultados	8
7. Herramienta virtual	10
8. Conclusiones	10
9. Dificultades	10
10.Trabajo futuro	11

## 1. Introducción

Una de las causas comunes de estrés y malestar psicológico de los estudiantes universitarios es la carga académica, que presenta múltiples factores asociados al bienestar emocional de los alumnos. Desde la dificultad misma del ramo hasta la demanda en tiempo que significa la asignatura pueden ser algunos de estos factores. Por ello, tanto para la universidad como para los estudiantes es necesario desarrollar herramientas que ayuden a un mejor enfrentamiento de la carga académica. Dentro de los distintos aspectos que se pueden abordar para resolver este problema existe la opción de ayudar a los estudiantes a planificar mejor sus mallas curriculares, de tal forma de evitar semestres sobrecargados que puedan culminar en un desequilibrio académico. Desde una perspectiva de la minería de datos esta solución es similar a diseñar un sistema recomendador de ramos, orientado a evitar el riesgo académico de los estudiantes.

Tomando los contenidos del curso se puede entonces hacer una aproximación a un sistema recomendador que, basándose en la experiencia de alumnos previos (base de datos) permita consultar qué combinaciones de ramos según cada alumno tendrán más probabilidad de causar un desequilibrio académico.

Por lo tanto, el objetivo final o problemática que se quiere resolver con el procesamiento de datos y las predicciones correspondientes es evitar la toma de ramos que en un mismo semestre puedan causar un riesgo académico para el estudiante, con el trasfondo de disminuir el malestar emocional de los alumnos.

En el presente documento se expondrán todos los aspectos necesarios para el desarrollo de la herramienta planteada.

## 2. Descripción de los datos

### Dataset

Para la realización del proyecto haremos uso de tres *datasets* que nos proporcionó la Dirección de Pregrado. Estos contienen la información de todos los ramos cursados hasta el presente año por los alumnos de las admisiones **2015, 2016 y 2017**. Cada fila del *dataset* representa un curso que fue tomado por un alumno en un semestre y año en específico, junto con su nota final. Cabe destacar que los datos están anonimizados, y es por esto que se cuenta con un código de identificación especial para cada alumno.

Otro aspecto importante a notar es que los cursos que fueron retirados durante un semestre en particular no fueron contabilizados dentro de los *datasets*.

Las columnas del *dataset* son las siguientes:

Columna	Explicación
COD ALUMNO	Llave única que representa a un alumno.
AÑO ADMISIÓN	Año de ingreso del alumno a la universidad.
PROGRAMA CÓDIGO	Código del programa inscrito, este puede hacer referencia a Ingeniería Civil Plan Común o al Diplomado inscrito si es que tiene.
PROGRAMA	Nombre del programa inscrito (plan común o diplomado)
MAJOR CÓDIGO SELECCIONADO	Código del mayor inscrito por el alumno. Como solo se están analizando alumnos de los años 2015 a 2017, todos poseen majors inscritos, por lo que esta columna no podrá tomar valores NaN.
	Nombre del mayor inscrito por el alumno.
MINOR SELECCIONADO	Nombre del menor inscrito.
AÑO	Año en el que se cursó el ramo.
SEMESTRE	Semestre en el que se cursó el ramo. (1 o 2)
SIGLA	Sigla del ramo.
SECCIÓN	Sección cursada.
NOMBRE CURSO	Nombre del ramo.
CRÉDITOS CURSO	Créditos del curso.
NOTA FINAL	Nota final del ramo en una escala de 1 a 7.
NOTA FINAL ALFA	Nota final del ramo en una escala alfabética. Un ramo puede tener una nota en escala numérica o alfabética, en cualquier caso, una de las columnas quedará con valores NaN.

A continuación se muestra un ejemplo de fila dentro del *dataset*:

	COD ALUMNO	AÑO ADMISIÓN	PROGRAMA CÓDIGO	PROGRAMA	MAJOR CÓDIGO SELECCIONADO	MAJOR SELECCIONADO	MINOR CÓDIGO SELECCIONADO	MINOR SELECCIONADO	AÑO	SEMESTRE	SIGLA	SECCIÓN	NOMBRE CURSO	CRÉDITOS CURSO	NOTA FINAL	NOTA FINAL ALFA
0	330775	2015	40013	INGENIERÍA CIVIL	M133	MAJOR EN COMPUTACIÓN E INGENIERÍA DE SOFTWARE ...	N161	MINOR DE PROFUNDIDAD EN DATA SCIENCE Y ANALYTICS	2015	1	ING1004	8.0	DESAFÍOS DE LA INGENIERÍA	10.0	5.6	NaN

Figura 1: Ejemplo fila *dataset*

### 3. Exploración de datos

#### Limpieza de Datos

Para el proyecto no necesitaremos ciertas columnas por diversas razones, en el siguiente apartado se muestra cada columna que no será utilizada con su respectiva justificación:

- **NOTA FINAL ALFA:** Estas notas no aplican a los cursos que vamos a analizar.
- **PROGRAMA:** Todos los datos por analizar se encuentran en el programa Ingeniería Civil, por lo que no aporta información.
- **PROGRAMA CÓDIGO:** Solo se considerará el código 40013.
- **SECCIÓN:** No afecta en nuestro análisis.
- **MAJOR SELECCIONADO:** Se utilizará el código del mayor, por lo que esta columna ya no es necesaria. Sin embargo, no es descartada completamente, pues puede ser útil en términos de análisis de datos y futura visualización.

- **MINOR SELECCIONADO:** Se utilizará el código del minor, por lo que esta columna ya no es necesaria
- **Valores NaN:** Se eliminarán todas las filas con valores NaN, pues son aquellas en donde las notas de los ramos son alfabéticas, por lo tanto no aporta información al análisis.

## Definiciones y consideraciones

A continuación se explicarán las definiciones y consideraciones relevantes para el desarrollo de la predicción y análisis de resultados.

- **Alumnos similares académicamente:** Los atributos a considerar para comparar alumnos serán los siguientes:
  1. **CRÉDITOS INSCRITOS:** Es relevante saber en que etapa de la carrera se encuentra el alumno, por lo que se compararán únicamente alumnos que se encuentren en un rango de créditos similar, con una variación máxima de 100 créditos. Cabe destacar, que no es necesario que los estudiantes actualmente se encuentren en la misma etapa de la carrera.
  2. **PPA:** Promedio ponderado acumulado semejante. Este se debe calcular considerando los créditos tomados. Es decir, dos personas se comportan de manera parecida si es que tienen un PPA similar con X cantidad de créditos inscritos.
  3. **MAJOR:** Que se encuentren inscritos en majors iguales o compatibles (i.e. que compartan un número de cursos mayor o igual a cierto umbral).
  4. **MAX PROMEDIO:** Que su promedio más alto no supere un umbral de diferencia entre ambos. Siempre que estos promedios sean los máximos hasta el mismo semestre para ambos alumnos.
  5. **MAX SIGLA:** Que el ramo en el que tuvieron un mejor rendimiento sea similar, es decir, que pertenezcan al mismo departamento, esto lo podemos identificar mediante las tres primeras letras del curso. (MAT, IIC, FIS, entre otros). Siempre que estos ramos sean los máximos hasta el mismo semestre para ambos alumnos.
  6. **MIN PROMEDIO:** Que su promedio más bajo no supere un umbral de diferencia entre ambos. Siempre que estos promedios sean los máximos hasta el mismo semestre para ambos alumnos.
  7. **MIN SIGLA:** Que el ramo en el que tuvieron un peor rendimiento sea similar. Siempre que estos promedios sean los máximos hasta el mismo semestre para ambos alumnos.
- **Riesgo académico:** Se definirá el riesgo académico cuando:

$$PPA - PROMEDIO FINAL_i \geq UMBRAL$$

Con UMBRAL un número decimal positivo.

En otras palabras, si es que la variación entre el PPA del estudiante y el promedio final en el curso  $i$  es lo suficientemente alta para disminuir su promedio, se considerará que hay un riesgo académico.

Cabe destacar que si el  $PROMEDIO FINAL_i$  es mayor que el PPA, entonces la diferencia será negativa, por lo que nunca superará el UMBRAL.

- **Riesgo de reprobación:** Se definirá el riesgo de reprobación cuando:

$$PROMEDIO FINAL_i \sim 4,0$$

Es decir, cuando el promedio en el curso  $i$  es similar o menor a 4.0.

## Visualización de los datos

Los datos revelan comportamientos interesantes que a veces muestran tener ciertas tendencias. A continuación se muestran tres gráficos ajustados a una distribución Normal, con los datos de cohortes de los años 2015, 2016 y 2017.




Figura 2: Notas de las cohortes 2015, 2016 y 2017

Se puede observar que las 3 cohortes comparten desviaciones y medias bastante similares. Otro análisis interesante que se puede realizar es ver cómo varían las notas de los estudiantes en cierto ramo según el PPA que poseen, a continuación se muestra el gráfico Nota Final EYP1113 vs PPA:




Figura 3: Notas EYP1113 semestres 2016-2 y 2017-2

Se puede apreciar que aquellos puntos coloreados en rojo son los alumnos que reprobaron el ramo, mientras que los azules son quienes lo aprobaron. Además, se puede ver que hay una clara correlación en ambos casos entre el PPA de los estudiantes junto a su nota final en el ramo.

Para poder realizar análisis similares con este u otros ramos se recomienda utilizar el *notebook Análisis de datos*.

## 4. Temática central del proyecto

El proyecto se centrará en predecir el riesgo académico y riesgo de reprobación de un estudiante en base a los ramos que desea tomar en un semestre. Considerando su PPA, créditos inscritos hasta el momento, sigla y promedio del mejor y peor curso que ha tenido hasta el momento, mayor inscrito y créditos inscritos en el semestre que se busca predecir. De esta manera, se puede ayudar a prevenir casos de reprobación de cursos, o bien, advertir que la carga académica de cierta combinación de ramos puede traer riesgos académicos en un semestre. Esto puede alivianar el estrés futuro que puedan sufrir ciertos estudiantes por inscribir una combinación de cursos que puedan perjudicar a su rendimiento académico y salud mental.

Cabe aclarar, que el estudiante que quiere consultar, deberá ingresar a la interfaz únicamente las siglas de **dos ramos** en los que quiera predecir su rendimiento académico al tomarlos juntos, esto porque si se ingresa una cantidad mayor se reduciría mucho el dataset de predicción, lo que haría que finalmente no se pueda asegurar un resultado confiable. Lo anterior también se justifica en base a que es común que se tomen 2 ramos de alta dificultad y 3 ramos de mediana o baja dificultad para equilibrar la carga académica.

Un aspecto importante a considerar es que debido a la gran variedad de cursos que existen en la malla de Ingeniería UC, la cantidad de datos que tenemos no permiten realizar una buena predicción para aquellas personas que están muy avanzadas en la malla, ya que no poseemos suficiente información para poder predecir su rendimiento académico, por lo que optamos por enfocar el proyecto a aquellos semestres en los que los estudiantes tienen a lo más 300 créditos aprobados.

## 5. Descripción del proceso

Para abordar el problema se decidió utilizar un proceso de filtrado de datos y posteriormente el modelo de predicción KNN, en donde se transformará cada estudiante en un vector del espacio, para luego encontrar a sus vecinos más cercanos y de esta manera comparar su rendimiento en los ramos que se buscan.

### Filtrado

Ejemplo de dataset construido previo al proceso:

```
(['FIS1523', 'MAT1630', 'MAT1640', 'IIC2233', 'TTF027'],  
 [ 5.8, 6.0, 4.5, 5.4, 7.0],  
 ppa= 5.6,  
 mejor promedio hasta este semestre = 6.6,  
 peor promedio hasta este semestre = 4.1,  
 major inscrito = 'MAJOR COMPUTACIÓN',  
 sigla mejor promedio = 'MAT1610',  
 sigla peor promedio = 'LET003',  
 creditos inscritos hasta el semestre = 100,  
 creditos inscritos en el semestre = 50)
```

Este procedimiento constará de 2 etapas:

- i) Filtrar a los individuos que no sean iguales en ciertas columnas específicas:

Como ejemplo, si un alumno quiere predecir cómo será su rendimiento académico si toma los ramos IIC2233 y MAT1630, entonces se filtrarán en el dataset todos los alumnos que hayan incorporado estos ramos en su semestre, dejando afuera los que no tienen esos ramos en el semestre. Además, cabe la posibilidad de que filtremos por otros atributos que consideremos relevantes, como por ejemplo por la cantidad de créditos que tomó el alumno en el semestre, esto puede variar dependiendo de cómo sea el rendimiento de nuestro modelo.

Una vez que se aplique el proceso de filtrado para el ejemplo anterior quedaria el siguiente vector:

```
(['FIS1523', 'MAT1630'],  
 [5.8, 6.0],  
 ppa= 5.6,  
 mejor promedio hasta este semestre = 6.6,  
 peor promedio hasta este semestre = 4.1,  
 major inscrito = 'MAJOR COMPUTACIÓN',  
 sigla mejor promedio = 'MAT',
```

```
sigla peor promedio = 'LET',  
creditos inscritos hasta el semestre = 100)
```

Los atributos eliminados fueron: créditos inscritos, tres ramos y sus respectivos promedios.

ii) Con los individuos que pasan el filtro se realiza la búsqueda de vecinos más cercanos por KKN:

En el caso del ejemplo, como el vector cumplía con los requisitos será utilizado en la búsqueda de los vecinos.

## Testing y Training Sets

Como se mencionó en la exploración de datos, para predecir el riesgo académico y el riesgo de reprobación de los ramos necesitamos predecir la nota final de los estudiantes en los ramos, para esto dividimos nuestro dataset en las matrices X e Y, donde Y contiene las notas de los ramos que se buscan predecir y X contiene el resto de los datos. Luego, se dividió el dataset en 2 nuevos sets, uno de *training* y otro de *testing* con el método `train_test_split` de la librería `sklearn`.

## KNN

Se desarrollaron dos tipos de modelos en KNN, el primero fue un *KNeighborsClassifier* y el segundo un *KNeighborsRegressor*, para el primero clasificamos todas las notas en intervalos entre [1, 2), [2, 3), [3, 4), [4, 5), [5, 6) y [6, 7], mientras que para el segundo utilizamos las notas como *floats*.

Además, para cada modelo se tomarón en cuenta distintas *features* con el fin de poder generar más modelos y comparar cuales generaban mejores resultados. En el primer caso, se tomaron en cuenta los atributos de CRÉDITOS PREVIOS, PPA, MAX PROMEDIO y MIN PROMEDIO. Mientras que, en segunda instancia se consideraron los atributos previos junto con MAX SIGLA, MIN SIGLA y MAJOR, al ser estos atributos nominales, se utilizó *One Hot Encoding* para poder realizar KNN con ellos.

Con el fin de poder analizar la importancia de las variables mencionadas previamente, se decidió mantener el número de vecinos constante para todos los modelos. Para esto se fue variando el k hasta encontrar aquel que entregaba los mejores resultados, siendo el k de vecinos igual a 5 para todos los modelos.

Entonces, se utilizaron un total de cuatro modelos, estos se describen a continuación:

1. **KNeighborsRegressor sin datos categóricos:** Las notas a predecir son de tipo **numérico** y se **omiten** en este caso las columnas MIN\_SIGLA, MAX\_SIGLA y MAJOR CÓDIGO SELECCIONADO.
2. **KNeighborsRegressor con datos categóricos:** Las notas a predecir son de tipo **numérico** y se **incluyen** en este caso las columnas MIN\_SIGLA, MAX\_SIGLA y MAJOR CÓDIGO SELECCIONADO.
3. **KNeighborsClassifier sin datos categóricos:** Las notas a predecir son de tipo **intervalos** y se **omiten** en este caso las columnas MIN\_SIGLA, MAX\_SIGLA y MAJOR CÓDIGO SELECCIONADO.
4. **KNeighborsClassifier con datos categóricos:** Las notas a predecir son de tipo **intervalos** y se **incluyen** en este caso las columnas MIN\_SIGLA, MAX\_SIGLA y MAJOR CÓDIGO SELECCIONADO.

Para evaluar los modelos se utilizaron dos métricas diferentes:

- **Coefficiente de determinación:** Se utilizó para evaluar el rendimiento de los modelos *KNeighborsRegressor*. Además, se incluyó el parámetro `multioutput='raw_values'` para poder evaluar el rendimiento con la nota de ambos ramos.

- **Accuracy:** Se utilizó para evaluar el rendimiento de los modelos `KNeighborsClassifier`.

Adicionalmente, para cada modelo se evaluó su rendimiento aumentando el peso tanto de la columna **PPA** como de la columna **CRÉDITOS PREVIOS** al doble. Esto se hizo a través del parámetro `metric` al que se le entrega una función que calcula las nuevas distancias euclidianas considerando los nuevos pesos.

Finalmente, se disminuyó la dimensionalidad de los modelos clasificadores y regresores con mejores resultados con PCA, para descubrir si es que el rendimiento tenía una mejora.

## 6. Evaluación de Resultados

Por temas de tiempo de ejecución, se utilizaron únicamente 100 datos para predecir y posteriormente evaluar los distintos modelos. Sin embargo, es posible predecir con el set de test completo.

A continuación se muestran los resultados al evaluar los modelos:

	Datos categóricos	Sin modificaciones	metric - PCA	metric - Créditos Previos
Regresor	Sin	[0.36, 0.42]	[0.43, 0.50]	[0.33, 0.51]
	Con	[0.43, 0.34]	[0.45, 0.37]	[0.43, 0.36]
Clasificador	Sin	[0.45, 0.55]	[0.54, 0.54]	[0.52, 0.58]
	Con	[0.48, 0.49]	[0.50, 0.47]	[0.51, 0.50]

Los modelos que dieron mejores resultados fueron:

- **Clasificador:** `KNeighborsClassifier` sin datos categóricos con mayor peso en los créditos previos.
- **Regresor:** `KNeighborsRegressor` sin datos categóricos con mayor peso en el PPA.

Los resultados obtenidos al aplicar PCA sobre estos dos modelos y posteriormente entrenarlos y predecir con ellos fueron los siguientes:

- **Clasificador:** [0.47, 0.44]
- **Regresor:** [0.41, 0.35]

De esta manera, el modelo que obtuvo mejores resultados fue `KNeighborsClassifier` sin datos categóricos con mayor peso en los créditos previos y sin PCA.

### Visualización de resultados

Se realizaron visualizaciones de los mejores modelos usando PCA para determinar si existe alguna relación entre las componentes principales y la nota final obtenida. Considerando que los candidatos a vecinos cambian para cada estudiante (filtrados mediante la función mencionada en 5), se tomó a un estudiante aleatorio, y se hizo la visualización de su predicción de notas y los candidatos a vecinos con los que se realizó la predicción.




Scatter plot showing the first two principal components (PC1 and PC2) for 1350 individuals. The x-axis (PC1) ranges from -0.6 to 0.8, and the y-axis (PC2) ranges from -0.4 to 0.8. Points are colored by sex: males (blue) and females (green). A legend in the top left corner lists the first 10 individuals with their IDs, year, sex, and PC1/PC2 coordinates. A color bar on the right indicates the sex of each individual, with blue for males and green for females.

COD ALUNNO	ANNO	SEMESTRE	PC1	PC2
345360	2016	2	5.1	
356223	2017	2	4.5	
350944	2015	2	5.0	
331037	2015	2	5.1	
343806	2016	2	5.9	
355798	2017	2	4.4	
348164	2017	1	4.3	
353353	2015	2	4.9	
343857	2016	2	4.7	
330886	2015	2	3.0	

Name: NOTA\_RANDM.1 Length: 1350 dtype: float64

3.2400000000000007



## 7. Herramienta virtual

Se llevó a cabo una herramienta virtual para poner en práctica los resultados obtenidos, donde se utiliza el modelo que dió mejores resultados para predecir el rendimiento académico según los datos entregados por el usuario.

Para implementarla se utilizó Jupyter Notebook junto con Voilà, para posteriormente realizar el despliegue a Heroku.

Se puede acceder a la página mediante el siguiente [link](#).

## 8. Conclusiones

Se obtuvieron las siguientes conclusiones sobre los siguientes aspectos:

- **Tamaño del dataset:** A pesar de tener una gran cantidad de datos, y al filtrar estudiantes similares en ocasiones se llegaron a muy pocos vecinos como para hacer la clasificación.
- **No hay mejoras en desempeño al incluir atributos nominales:** Al utilizar los datos nominales (siglas de mejor y peor promedio, mayor inscrito) no llevaron a una clara diferencia entre utilizarlos o no, e incluso en algunos casos los resultados fueron peores. Por otro lado, al visualizar los datos solo se observan divisiones en grupos de estudiantes.
- **Usabilidad de la herramienta:** La herramienta demostró poder predecir con más de un 50 % de certeza el futuro desempeño de un estudiante en dos cursos futuros, lo que implica que puede ser de gran utilidad pero se deberían agregar mejoras para que en la práctica pueda ayudar de mejor manera al estudiantado.
- **Público objetivo:** El modelo es de mayor utilidad para estudiantes que se encuentren en inicios de la carrera, pues existe una mayor cantidad de estudiantes similares.
- **Atributos de mayor peso:** Al variar parámetros se encontró que al aumentar el peso del PPA se obtienen mejores resultados en el modelo Regresor. En cambio, al aumentar el peso de los créditos previos en el modelo Clasificador se obtienen mejores resultados. Sin embargo, en este último, los resultados al aumentar el PPA son bastante similares.
- **Mejorar el análisis con otros modelos:** Para saber con certeza la mejor predicción posible es necesario implementar otros modelos predictivos sobre el dataset y comparar los resultados de sus respectivas evaluaciones con KNN.

## 9. Dificultades

Respecto a los aspectos externos al proceso de minería de datos, se puede mencionar que conseguir el dataset tomó una dificultad no menor ya que se tuvo que incurrir en solicitarlo a la dirección de Pregrado de la Facultad de Ingeniería y además se debió firmar un acuerdo de confidencialidad con los datos. Además la Escuela no entregó los datos de los alumnos que botaron ramos, lo que implicó trabajar con la información incompleta.

En relación al proceso de trabajo con los datos, se descubrió que a pesar de contener una gran cantidad de datos ( $\sim 3$  mil estudiantes), en muchos casos debido a las restricciones impuestas existen muchos casos donde las combinaciones son tal, que no se encuentran vecinos cercanos por lo que se imposibilita realizar predicciones.

Otro aspecto que también tomó dificultad fue visualizar los datos para poder tomar decisiones rápidas en el ajuste del modelo, ya que los vectores con los que se trabajó tenían más de 3 dimensiones entonces la única forma de observar los datos fue a través de PCA. Si bien es una gran herramienta, no se permitía ver el efecto de cada dimensión por separado.

Respecto al modelo, en base a los coeficientes de evaluación obtenidos se puede considerar que las predicciones fueron relativamente certeras. A pesar de que la diferencia entre los valores estimados con los reales sea cercana a las 0.5 décimas, el modelo presenta ser útil para el propósito con el que está construido.

Como consejos para continuar el proyecto, se recomienda lo siguiente:

- Testear con distintos modelos, tanto clasificadores como regresores: Dado que todos los resultados obtenidos fueron provenientes de las predicciones de KNN, se recomienda obtener el análisis hecho por otros modelos como DecisionTree, RandomForest, entre otros con el fin de observar si se pueden alcanzar resultados más exactos.
- Considerar las columnas de mayor varianza: Después del proceso desarrollado fue claro que el ajuste del modelo con datos difíciles de visualizar y comprender resulta tedioso por lo tanto se recomienda revisar la matriz de covarianzas de los datos y trabajar solo con las dos columnas de mayor varianza del dataset, para así comprender el efecto directo de las dimensiones sobre las predicciones y tener más facilidad de exploración de resultados.

## 10. Trabajo futuro

Para continuar con este proyecto sería muy beneficioso realizar lo siguiente:

- Conseguir una mayor base de datos: Para poder predecir a alumnos que tienen vecinos escasos como ocurre con los estudiantes de últimos años. Bajo la misma lógica de conseguir más vecinos, se podría también generar la predicción para una combinación de tres ramos, lo que sería aún más útil para aquel estudiante que esté planificando su semestre académico.
- Mejorar el preprocesamiento de datos: Observar la presencia de datos ruidosos u outliers y eliminarlos como posibles vecinos, ya que estos podrían estar perturbando la predicción.
- Encontrar el mejor K: Hacer múltiples pruebas con distinta cantidad de vecinos hasta encontrar el valor de K óptimo para hacer buenas predicciones. Esto posiblemente vaya a cambiar cuando la base de datos sea mayor.